Projekt MED-P3, algorytm GRM. Raport.

Przedmiot: Metody eksploracji danych w odkrywaniu wiedzy.

Michał Aniserowicz, Jakub Turek

1 Opis zadania

Celem projektu jest zaimplementowanie algorytmu wyznaczania reguł decyzyjnych o minimalnych poprzednikach, które są częstymi generatorami. Algorytm ten jest modyfikacją algorytmu odkrywania częstych generatorów (GRM), opisanego w [1].

2 Założenia

Projekt zrealizowano w oparciu o następujące założenia:

2.1 Niefunkcjonalne:

1. Użyty język programowania; platforma: C#; .NET Framework 3.5.
2. Obsługiwane systemy operacyjne: kompatybilne z .NET Framework 3.5[1] (aplikację testowano na systemie Microsoft Windows 7 Ultimate).
3. Rodzaj aplikacji: aplikacja konsolowa uruchamiana z wiersza poleceń.

2.2 Funkcjonalne:

1. Aplikacja pobiera dane z pliku (patrz sekcja 3.1).
2. Aplikacja zwraca wynik działania w dwóch formatach: "przyjaznym dla człowieka" i "excelowym" (patrz sekcja 4).
3. Aplikacja pozwala mierzyć czas wykonania poszczególnych kroków algorytmu.

2.3 Dotyczące danych wejściowych:

1. Dane wejściowe zawierają jedynie wartości atrybutów transakcji i ewentualnie nazwy atrybutów transakcji.
2. Wartości atrybutów w pliku wejściowym są oddzielone przecinkami.
3. Każda transakcja ma przypisaną decyzję.
4. Brakujące wartości atrybutów (tzn. wartości nieznane bądź nieustalone) są oznaczone jako wartości puste lub złożone z białych znaków.

3 Dane wejściowe

Aplikacja będąca wynikiem projektu przyjmuje jednocześnie dwa rodzaje danych wejściowych:

- plik zawierający dane transakcji,
- parametry podane przez użytkownika w wierszu poleceń.

[1] Lista systemów kompatybilnych z .NET Framework 3.5 dostępna jest pod adresem: *http://msdn.microsoft.com/en-us/library/vstudio/bb882520%28v=vs.90%29.aspx*, sekcja "Supported Operating Systems".

3.1 Plik wejściowy

Plik wejściowy powinien zawierać kolejne wartości atrybutów transakcji według reguł przedstawionych w sekcji 2.3. Przykładowy format pliku wejściowego:

```
a,b,c,d,e, ,g, ,+
a,b,c,d,e,f, , ,+
a,b,c,d,e, , ,h,+
a,b, ,d,e, , , ,+
a, ,c,d,e, , ,h,-
 ,b,c, ,e, , , ,-
```

Opcjonalnie, pierwszy wiersz pliku wejściowego może zawierać nazwy atrybutów transakcji (nagłówki), na przykład:

```
Attr A,Attr B,Attr C,Attr D,Attr E,Attr F,Attr G,Attr H,Decision
a,b,c,d,e, ,g, ,+
 ,b,c, ,e, , , ,-
```

Jeden z atrybutów transakcji musi reprezentować przypisaną jej decyzję. Domyślnie, aplikacja uznaje ostatni atrybut transakcji za "decyzyjny" - użytkownik może jednak samodzielnie wskazać odpowiedni atrybut (patrz sekcja 3.2).

3.2 Parametry wiersza poleceń

Aplikacja przyjmuje następujące parametry:

- `--help` - Powoduje wyświetlenie informacji o dostępnych parametrach i wyjście z programu.
- `-f, --file=VALUE` - Ścieżka do pliku wejściowego. Parametr wymagany.
- `--sup, --minSup=VALUE` - Próg (bezwzględny) wsparcia - wykryte zostaną reguły decyzyjne o poprzednikach cechujących się wsparciem większym **lub równym** progowi wsparcia. Parametr wymagany.
- `-h, --headers` - Flaga oznaczająca, że plik wejściowy zawiera nagłówki atrybutów. Parametr opcjonalny.
- `--dec, --decAttr=VALUE` - Pozycja atrybutu zawierającego wartości decyzji (`1` - pierwszy atrybut, `2` - drugi atrybut itd.). Parametr opcjonalny (jeśli nie zostanie podany, ostatni atrybut zostanie uznany za decyzyjny).
- `--sort=VALUE` - strategia sortowania elementów (patrz sekcja 6.1). Parametr opcjonalny. Dopuszczalne wartości:
  - `AscendingSupport` (lub `0`; wartość domyślna),
  - `DescendingSupport` (lub `1`),
  - `Lexicographical` (lub `2`).
- `--store=VALUE` - strategia przechowywania identyfikatorów transakcji (patrz sekcja 6.2). Parametr opcjonalny. Dopuszczalne wartości:
  - `TIDSets` (lub `0`; wartość domyślna),
  - `DiffSets` (lub `1`).
- `--supgen=VALUE` - Strategia przechowywania generatorów decyzji, a także wykrywania i usuwania ich nadgeneratorów (patrz sekcja 6.3). Parametr opcjonalny. Dopuszczalne wartości:
  - `InvertedLists` (lub `0`; wartość domyślna),
  - `BruteForce` (lub `1`).

- `--track=VALUE` - Poziom monitorowania wydajności programu (patrz sekcja 6.4). Parametr opcjonalny.
  - `NoTracking` (lub `0`),
  - `Task` (lub `1`; wartość domyślna).
  - `Steps` (lub `2`).
  - `Substeps` (lub `3`; Uwaga: może powodować znaczący spadek ogólnej wydajności programu).
- `-o, --output=VALUE` - Ścieżka plików wyjściowych. Parametr opcjonalny. Poprawna wartość jest ścieżką pliku z pominięciem jego rozszerzenia (np. *wyniki/wynik*. Wartość domyślna: *[ścieżka pliku wejściowego]_rules*.

4 Dane wyjściowe

Na wyjście aplikacji składają się trzy rodzaje danych:

- komunikaty diagnostyczne wypisywane na standardowe wyjście,
- plik zawierący znalezione reguły decyzyjne w formacie czytelnym dla człowieka,
- plik zawierący znalezione reguły decyzyjne w formacie przystosowanym do dalszej obróbki.

4.1 Plik czytelny dla człowieka

Plik w formacie czytelnym dla człowieka zawiera listy generatorów dla każdej decyzji. Pojedynczy generator jest przedstawiony jako lista wartości atrybutów wraz z ich nazwami. Przykład:

```
====================
Decision: '+':
--------------------
Attr A (a), Attr B (b)
Attr B (b), Attr D (d)
```

Plik ten jest zapisywany pod ścieżką *[plik].txt*, gdzie *[plik]* to wartość parametru `output` (patrz sekcja 3.2).

4.2 Plik przystosowany do dalszej obróbki

Plik w formacie czytelnym dla człowieka zawiera listę generatrów wraz generowanymi przez nie decyzjami. Pojedynczy generator jest przedstawiony jako lista wartości oddzielonych średnikami[2], z uwzględnieniem atrybutów niewystępujących w generatorze. Przykład:

```
Attr A;Attr B;Attr C;Attr D;Attr E;Attr F;Attr G;Attr H;Decision
a;b;;;;;;;+
;b;;d;;;;;+
```

Plik ten jest zapisywany pod ścieżką *[plik].csv*, gdzie *[plik]* to wartość parametru `output` (patrz sekcja 3.2).

[2]Patrz http://pl.wikipedia.org/wiki/CSV_(format_pliku). W omawianej aplikacji zamiast przecinków użyto średników, aby plik wyjściowy mógł być odczytany przez program Microsoft Excel.

5 Architektura aplikacji

Aplikacja składa się z następujących modułów:

- `GRM.Logic` - zawiera implementację zmodyfikowanego algorytmu GRM,
- `GRM.Logic.UnitTests` - zawiera testy jednostkowe modułu `GRM.Logic`,
- `GRM.Logic.PerformanceTests` - zawiera testy wydajnościowe modułu `GRM.Logic`,
- `GRM.Presentation` - aplikacja konsolowa przetwarzająca argumenty wiersza poleceń i wywołująca algorytm GRM.

5.1 Moduł GRM.Logic

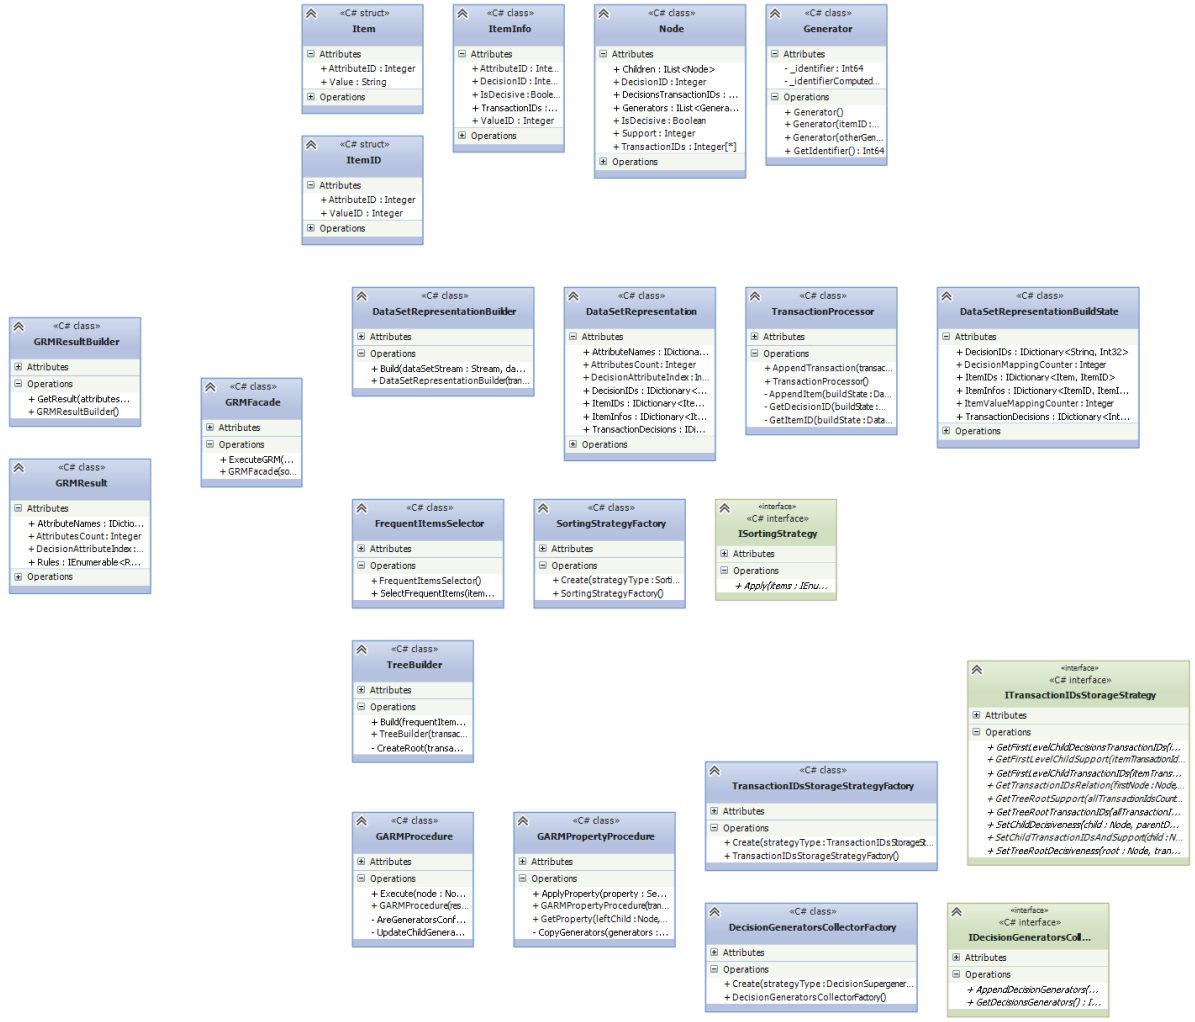

Rysunek 1: Uproszczony diagram klas modułu GRM.Logic.

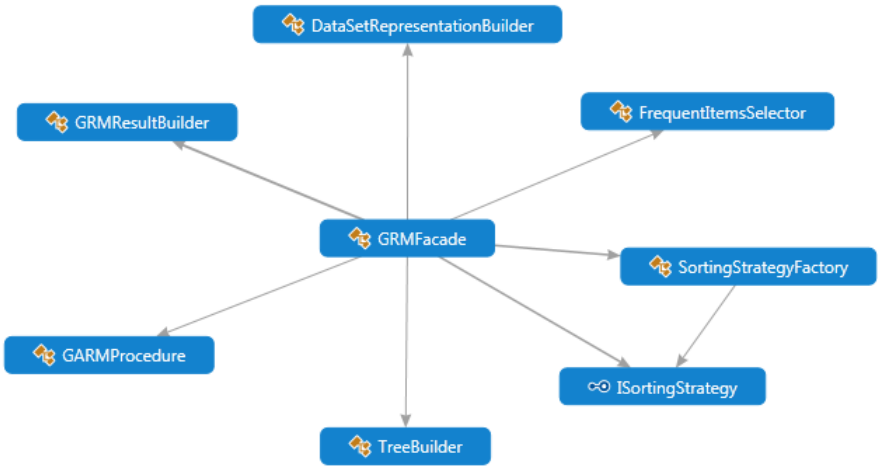

Rysunek 2: Uproszczony diagram zależności fasady modułu GRM.Logic.

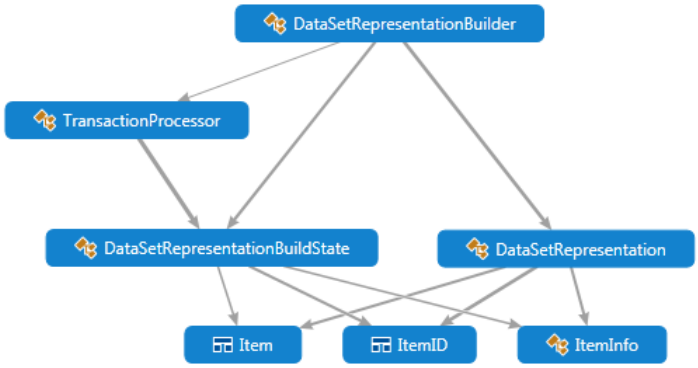

Rysunek 3: Uproszczony diagram zależności komponentu GRM.Logic.DataSetProcessing.

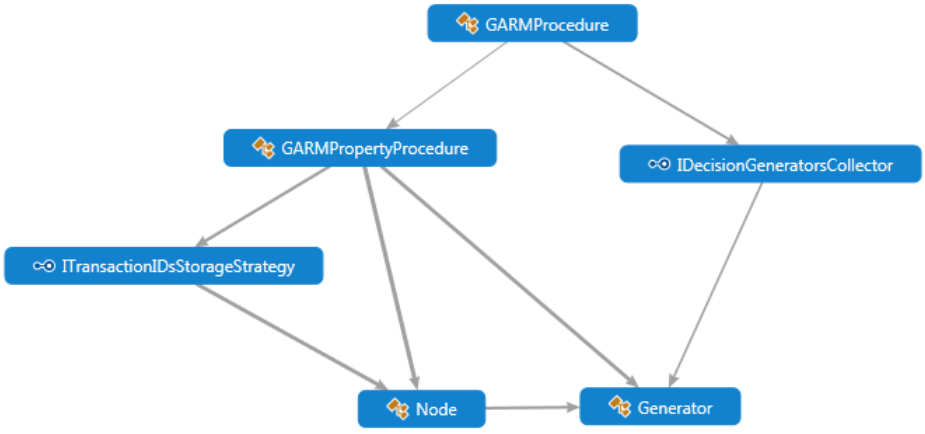

Rysunek 4: Uproszczony diagram zależności komponentu GRM.Logic.GRMAlgorithm.

5.1.1 Komponent GRM.Logic.DataSetProcessing

5.1.2 Komponent GRM.Logic.GRMAlgorithm

5.2 Moduł GRM.Presentation

Moduł `GRM.Presentation` odpowiada za komunikację z użytkownikiem aplikacji i zlecenie wykonania algorytmu GRM. Jego diagram klas przedstawia Rysunek 1.

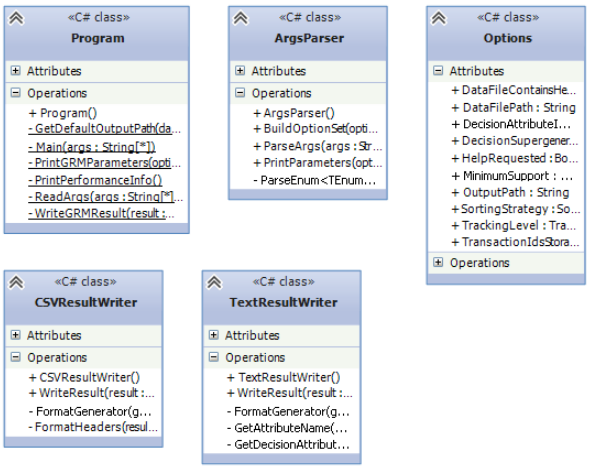

Rysunek 5: Diagram klas modułu GRM.Presentation.

Klasa `Program` zawiera główną metodę programu - `Main`. Jej działanie przebiega następująco:

1. Odczytanie parametrów wiersza poleceń (klasa `ArgsParser`). Błędne parametry skutkują wypisaniem komuniaktu o błędzie i wyjściem z aplikacji.
2. Przekazanie sterowania modułowi `GRM.Logic` (klasie `GRMFacade`).
3. Odebranie wyniku działania algorytmu GRM (`GRMResult`) od klasy `GRMFacade`.
4. Wypisanie zebranych danych o czasach trwania kolejnych kroków algorytmu (patrz sekcja 6.4).
5. Zapisanie wyniku działania algorytmu do pliku wyjściowego w formacie czytelnym dla człowieka (klasa `TextResultWriter`).
6. Zapisanie wyniku działania algorytmu do pliku wyjściowego w formacie przystosowanym do dalszej obróbki (klasa `CSVResultWriter`).

Opisane zachowanie obrazuje diagram zależności pokazany na Rysunku 6.

6 Implementacja

Najważniejsze aspekty implementacyjne opisywanej aplikacji:

6.1 Strategie sortowania elementów

Zaimplementowano następujące strategie sortowania elementów w drzewie zbiorów (drzewie DZ [1]):

- `AscendingSupport` (klasa `AscendingSupportSortingStrategy`) - sortowanie rosnące według wsparć elementów,
- `DescendingSupport` (klasa `DescendingSupportSortingStrategy`) - sortowanie malejące według wsparć elementów,

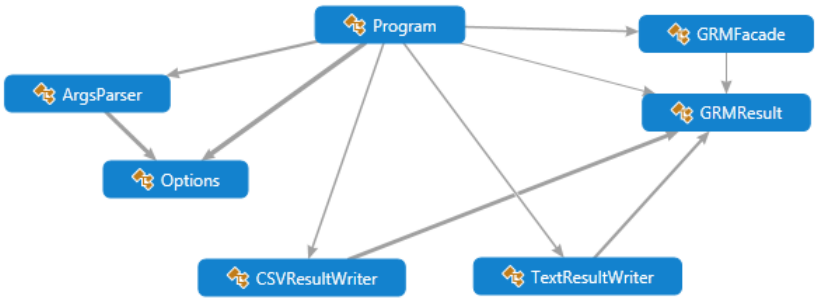

Rysunek 6: Diagram zależności modułu GRM.Presentation. Klasy GRMFacade i GRMResult należą do modułu GRM.Logic.

- `Lexicographical` (klasa `LexicographicalSortingStrategy`) - sortowanie leksykograficzne. tzn. według numerów atrybutów elementów (dla dwóch wartości tego samego atrybutu, pierwsza będzie ta, która wcześniej wystąpiła w zbiorze danych wejściowych).

Strategie sortowania dostarcza fabryka `SortingStrategyFactory`, tworząca strategie odpowiadające zadanym wartościom wyliczenia `SortingStrategyType`.

6.2 Strategie przechowywania identyfikatorów transakcji

Zaimplementowano następujące strategie przechowywania identyfikatorów transakcji:

- `TIDSets` [2] (klasa `TIDSetsStorageStrategy`),
- `DiffSets` [1] (klasa `DiffSetsStorageStrategy`).

Strategie przechowywania dostarcza fabryka `TransactionIDsStorageStrategyFactory`, tworząca strategie odpowiadające zadanym wartościom wyliczenia `TransactionIDsStorageStrategyType`.

6.3 Strategie przechowywania generatorów decyzji

Zaimplementowano następujące strategie przechowywania generatorów decyzji, a także wykrywania i usuwania ich nadgeneratorów:

- `InvertedLists` (klasa `InvertedListsDecisionGeneratorsCollector`) - wykorzystuje koncepcję indeksu odwróconego[3], gdzie kluczem indeksu jest element, a wartością - lista generatorów, w których ten element występuje,
- `BruteForce` (klasa `BruteForceDecisionGeneratorsCollector`) - przechowuje jedynie listę generatorów, nadgeneratory wykrywa porównując każdy element danego generatora z każdym elementem jego potencjalnego nadgeneratora.

Strategie dostarcza fabryka `DecisionGeneratorsCollectorFactory`, tworząca strategie odpowiadające zadanym wartościom wyliczenia `DecisionSupergeneratorsHandlingStrategyType`.

6.4 Monitorowanie wydajności programu

Aplikacja udostępnia funkcjonalność mierzenia czasu wykonania poszczególnych kroków algorytmu. Zaimplementowano następujące rodzaje pomiaru:

- `NoTracking` (klasa `EmptyProgressTracker`) - brak pomiaru wydajności,

[3] Patrz http://en.wikipedia.org/wiki/Inverted_index.

- `Task` (klasa `TaskProgressTracker`) - pomiar czasu trwania całego algorytmu,
- `Steps` (klasa `StepProgressTracker`) - pomiar czasu trwania głównych kroków algorytmu (odczyt danych wejściowych, wykonanie procedury *GARM* itd.),
- `Substeps` (klasa `SubstepProgressTracker`) - pomiar czasu trwania mniejszych kroków algorytmu (budowanie słownika identyfikatorów decyzji, wykonanie procedury *GARM-Property* itd.). Uwaga: może powodować znaczący spadek ogólnej wydajności programu.

Obiekty monitorujące dostarcza fabryka `ProgressTrackerFactory`, tworząca obiekty odpowiadające zadanym wartościom wyliczenia `TrackingLevel`.

6.5 Zabiegi optymalizacyjne

- Aby zminimalizować czas odczytu danych wejściowych, plik wejściowy jest odczytywany jednokrotnie, wiersz po wierszu.
- Aby zminimalizować czas trwania porównań, wszystkie wartości atrybutów otrzymują identyfikatory liczbowe.
- Aby zminimalizować czas operacji (np. przecięcia, różnicy) na zbiorach identyfikatorów transakcji, identyfikatory te są przechowywane w ustalonym (rosnącym) porządku.
- Aby możliwie wcześnie "odciąć" gałęzie drzewa, które nie prowadzą do znalezienia generatorów decyzji:
  - jeśli dwa węzły zawierają różne wartości tego samego atrybutu, to nie są "parowane" (tzn. poddawane procedurze *GARM-Property*) - przecięcie zbiorów identyfikatorów transakcji, w których występują jest puste, a zatem ich potencjalne dziecko nie może generować żadnej decyzji;
  - jeśli dany węzeł jest "decyzyjny" (tzn. generuje decyzję), to nie jest dalej rozwijany - generatory jego potencjalnych dzieci byłyby nadgeneratorami jego generatora.
- Jako że generator dowolnej decyzji D_1 nie może być nadgeneratorem żadnego generatora decyzji D_2 ($D_1 \neq D_2$), strategie przechowywania generatorów decyzji (patrz sekcja 6.3) przechowują generatory w słownikach, których kluczami są identyfikatory decyzji, a wartościami - zbiory generatorów tych decyzji. Pozwala to zminimalizować rozmiary porównywanych zbiorów generatorów.
- Granica GBd [1] nie jest tworzona i aktualizowana, jako że nie jest wykorzystywana w poszukiwaniu reguł decyzyjnych.

6.6 Praktyki programistyczne

- Test-Driven Development, TDD[4] - najważniejsze funkcjonalności aplikacji powstały zgodnie z zachowaniem kolejności: testy jednostkowe → implementacja → refaktoryzacja.
- Dependency Injection[5] - obiekty klas tworzonych i wykorzystywanych przez klasę `GRMFacade` nie tworzą swoich zależności samodzielnie, a otrzymują je z zewnątrz.
- Wzorce projektowe:
  - Fasada[6] (klasa `GRMFacade`),
  - Budowniczy[7] (para klas: `DataSetRepresentationBuilder` i `TransactionProcessor`),
  - Strategia[8] (strategie opisane wyżej),
  - Fabryka[9] (fabryki strategii opisane wyżej).

[4] Patrz http://pl.wikipedia.org/wiki/Test-driven_development.
[5] Patrz http://pl.wikipedia.org/wiki/Wstrzykiwanie_zależności.
[6] Patrz http://pl.wikipedia.org/wiki/Fasada_(wzorzec_projektowy).
[7] Patrz http://pl.wikipedia.org/wiki/Budowniczy_(wzorzec_projektowy).
[8] Patrz http://pl.wikipedia.org/wiki/Strategia_(wzorzec_projektowy).
[9] Patrz http://pl.wikipedia.org/wiki/Fabryka_abstrakcyjna_(wzorzec_projektowy).

6.7 Wykorzystane biblioteki zewnętrzne

1. *NDesk.Options*[10] - ułatwia przetwarzanie parametrów wiersza poleceń,
2. *xUnit.net*[11] - umożliwia tworzenie automatycznych testów jednostkowych,
3. *moq*[12] - wspiera tworzenie automatycznych testów jednostkowych.

7 Podręcznik użytkownika

podrecznik potencjalnego uzytkownika wytworzonego oprogramowania (zamierzam korzystać z niego podczas sprawdzania Panstwa rozwiazan) - wszystkie opcje programu - przykladowa komenda i wynik na konsoli

8 Analiza poprawności

wszystkie wyniki wytwarzane przez program otrzymane dla malego, przykladowego zbioru danych (w celu weryfikacji poprawnosci działania programu) - przyklad z konsultacji

9 Analiza wydajności

wyniki jakosciowe i ilosciowe na (np. czas dzialania; liczba wzorcow) uzyskane dla wiekszych (wielkich) zbiorow danych(np. z http://archive.ics.uci.edu/ml/ or http://fimi.cs.helsinki.fi/data/ lub uzgodnionych już wcześniej ze mna podczas konsultacji projektowych) - uzasadnic supergenerators Inverted Lists - ze sortowanie AscendingSupport - ze storage TIDSets - wykresy, wykresy - ze dla duzej liczby atrybutow malo wydajny

10 Wnioski

wnioski z realizacji projektu - ze trzeba by poprawic wykrywanie supergeneratorow - ze sortowanie ma duzy wplyw - ze ogolnie dziala spoczko (nursey)

Literatura

[1] *Odkrywanie reprezentacji generatorowej wzorców częstych z wykorzystaniem struktur listowych*, Kryszkiewicz M., Pielasa P., Instytut Informatyki, Politechnika Warszawska.

[2] *CHARM: An Efficient Algorithm for Closed Itemset Mining* [online], Zaki M., Hsiao C. http://epubs.siam.org/doi/pdf/10.1137/1.9781611972726.27 [dostęp: styczeń 2013].

[10] Patrz http://www.ndesk.org/Options.
[11] Patrz http://xunit.codeplex.com/.
[12] Patrz https://github.com/Moq/moq4.