Projekt MED-P3, algorytm GRM. Raport.

Przedmiot: Metody eksploracji danych w odkrywaniu wiedzy.

Michał Aniserowicz, Jakub Turek

1 Opis zadania

Celem projektu jest zaimplementowanie algorytmu wyznaczania reguł decyzyjnych o minimalnych poprzednikach, które są częstymi generatorami. Algorytm ten jest modyfikacją algorytmu odkrywania częstych generatorów (GRM), opisanego w [1].

2 Założenia

Projekt zrealizowano w oparciu o następujące założenia:

2.1 Niefunkcjonalne:

1. Użyty język programowania; platforma: C#; .NET Framework 3.5.
2. Obsługiwane systemy operacyjne: kompatybilne z .NET Framework 3.5[1] (aplikację testowano na systemie Microsoft Windows 7 Ultimate).
3. Rodzaj aplikacji: aplikacja konsolowa uruchamiana z wiersza poleceń.

2.2 Funkcjonalne:

1. Aplikacja pobiera dane z pliku (patrz sekcja 3.1).
2. Aplikacja zwraca wynik działania w dwóch formatach: "przyjaznym dla człowieka" i "excelowym" (patrz sekcja 4).
3. Aplikacja pozwala mierzyć czas wykonania poszczególnych kroków algorytmu.

2.3 Dotyczące danych wejściowych:

1. Dane wejściowe zawierają jedynie wartości atrybutów transakcji i ewentualnie nazwy atrybutów transakcji.
2. Wartości atrybutów w pliku wejściowym są oddzielone przecinkami.
3. Każda transakcja ma przypisaną decyzję.
4. Brakujące wartości atrybutów (tzn. wartości nieznane bądź nieustalone) są oznaczone jako wartości puste lub złożone z białych znaków.

3 Dane wejściowe

Aplikacja będąca wynikiem projektu przyjmuje jednocześnie dwa rodzaje danych wejściowych:

- plik zawierający dane transakcji,
- parametry podane przez użytkownika w wierszu poleceń.

[1] Lista systemów kompatybilnych z .NET Framework 3.5 dostępna jest pod adresem: *http://msdn.microsoft.com/en-us/library/vstudio/bb882520%28v=vs.90%29.aspx*, sekcja "Supported Operating Systems".

3.1 Plik wejściowy

Plik wejściowy powinien zawierać kolejne wartości atrybutów transakcji według reguł przedstawionych w sekcji 2.3. Przykładowy format pliku wejściowego:

```
a,b,c,d,e, ,g, ,+
a,b,c,d,e,f, , ,+
a,b,c,d,e, , ,h,+
a,b, ,d,e, , , ,+
a, ,c,d,e, , ,h,-
 ,b,c, ,e, , , ,-
```

Opcjonalnie, pierwszy wiersz pliku wejściowego może zawierać nazwy atrybutów transakcji (nagłówki), na przykład:

```
Attr A,Attr B,Attr C,Attr D,Attr E,Attr F,Attr G,Attr H,Decision
a,b,c,d,e, ,g, ,+
 ,b,c, ,e, , , ,-
```

Jeden z atrybutów transakcji musi reprezentować przypisaną jej decyzję. Domyślnie, aplikacja uznaje ostatni atrybut transakcji za "decyzyjny" - użytkownik może jednak samodzielnie wskazać odpowiedni atrybut (patrz sekcja 3.2).

3.2 Parametry wiersza poleceń

Aplikacja przyjmuje następujące parametry:

- `--help` - Powoduje wyświetlenie informacji o dostępnych parametrach i wyjście z programu.
- `-f, --file=VALUE` - Ścieżka do pliku wejściowego. Parametr wymagany.
- `--sup, --minSup=VALUE` - Próg (bezwzględny) wsparcia - wykryte zostaną reguły decyzyjne o poprzednikach cechujących się wsparciem większym **lub równym** progowi wsparcia. Parametr wymagany.
- `-h, --headers` - Flaga oznaczająca, że plik wejściowy zawiera nagłówki atrybutów. Parametr opcjonalny.
- `--dec, --decAttr=VALUE` - Pozycja atrybutu zawierającego wartości decyzji (`1` - pierwszy atrybut, `2` - drugi atrybut itd.). Parametr opcjonalny (jeśli nie zostanie podany, ostatni atrybut zostanie uznany za decyzyjny).
- `--sort=VALUE` - strategia sortowania elementów (patrz sekcja 6.2). Parametr opcjonalny. Dopuszczalne wartości:
  - `AscendingSupport` (lub `0`; wartość domyślna),
  - `DescendingSupport` (lub `1`),
  - `Lexicographical` (lub `2`).
- `--store=VALUE` - strategia przechowywania identyfikatorów transakcji (patrz sekcja 6.3). Parametr opcjonalny. Dopuszczalne wartości:
  - `TIDSets` (lub `0`; wartość domyślna),
  - `DiffSets` (lub `1`).
- `--supgen=VALUE` - Strategia przechowywania generatorów decyzji, a także wykrywania i usuwania ich nadgeneratorów (patrz sekcja 6.4). Parametr opcjonalny. Dopuszczalne wartości:
  - `InvertedLists` (lub `0`; wartość domyślna),
  - `BruteForce` (lub `1`).

- `--track=VALUE` - Poziom monitorowania wydajności programu (patrz sekcja 6.5). Parametr opcjonalny.
  - `NoTracking` (lub `0`),
  - `Task` (lub `1`; wartość domyślna).
  - `Steps` (lub `2`).
  - `Substeps` (lub `3`; Uwaga: może powodować znaczący spadek ogólnej wydajności programu).
- `-o, --output=VALUE` - Ścieżka plików wyjściowych. Parametr opcjonalny. Poprawna wartość jest ścieżką pliku z pominięciem jego rozszerzenia (np. *wyniki/wynik*. Wartość domyślna: *[ścieżka pliku wejściowego]_rules*.

4 Dane wyjściowe

Na wyjście aplikacji składają się trzy rodzaje danych:

- komunikaty diagnostyczne wypisywane na standardowe wyjście,
- plik zawierący znalezione reguły decyzyjne w formacie czytelnym dla człowieka,
- plik zawierący znalezione reguły decyzyjne w formacie przystosowanym do dalszej obróbki.

4.1 Plik czytelny dla człowieka

Plik w formacie czytelnym dla człowieka zawiera listy generatorów dla każdej decyzji. Pojedynczy generator jest przedstawiony jako lista wartości atrybutów wraz z ich nazwami. Przykład:

```
====================
Decision: '+':
--------------------
Attr A (a), Attr B (b)
Attr B (b), Attr D (d)
```

Plik ten jest zapisywany pod ścieżką *[plik].txt*, gdzie *[plik]* to wartość parametru `output` (patrz sekcja 3.2).

4.2 Plik przystosowany do dalszej obróbki

Plik w formacie czytelnym dla człowieka zawiera listę generatorów wraz generowanymi przez nie decyzjami. Pojedynczy generator jest przedstawiony jako lista wartości oddzielonych średnikami[2], z uwzględnieniem atrybutów niewystępujących w generatorze. Przykład:

```
Attr A;Attr B;Attr C;Attr D;Attr E;Attr F;Attr G;Attr H;Decision
a;b;;;;;;;+
;b;;d;;;;;+
```

Plik ten jest zapisywany pod ścieżką *[plik].csv*, gdzie *[plik]* to wartość parametru `output` (patrz sekcja 3.2).

[2]Patrz http://pl.wikipedia.org/wiki/CSV_(format_pliku). W omawianej aplikacji zamiast przecinków użyto średników, aby plik wyjściowy mógł być odczytany przez program Microsoft Excel.

5 Architektura aplikacji

Aplikacja składa się z następujących modułów:

- `GRM.Logic` - zawiera implementację zmodyfikowanego algorytmu GRM,
- `GRM.Logic.UnitTests` - zawiera testy jednostkowe modułu `GRM.Logic`,
- `GRM.Logic.PerformanceTests` - zawiera testy wydajnościowe modułu `GRM.Logic`,
- `GRM.Presentation` - aplikacja konsolowa przetwarzająca argumenty wiersza poleceń i wywołująca algorytm GRM.

5.1 Moduł GRM.Logic

Moduł `GRM.Logic` jest głównym modułem aplikacji. Zawiera implementację zmodyfikowanego algorytmu GRM. Jego diagram klas został przedstawiony na Rysunku 1[3].

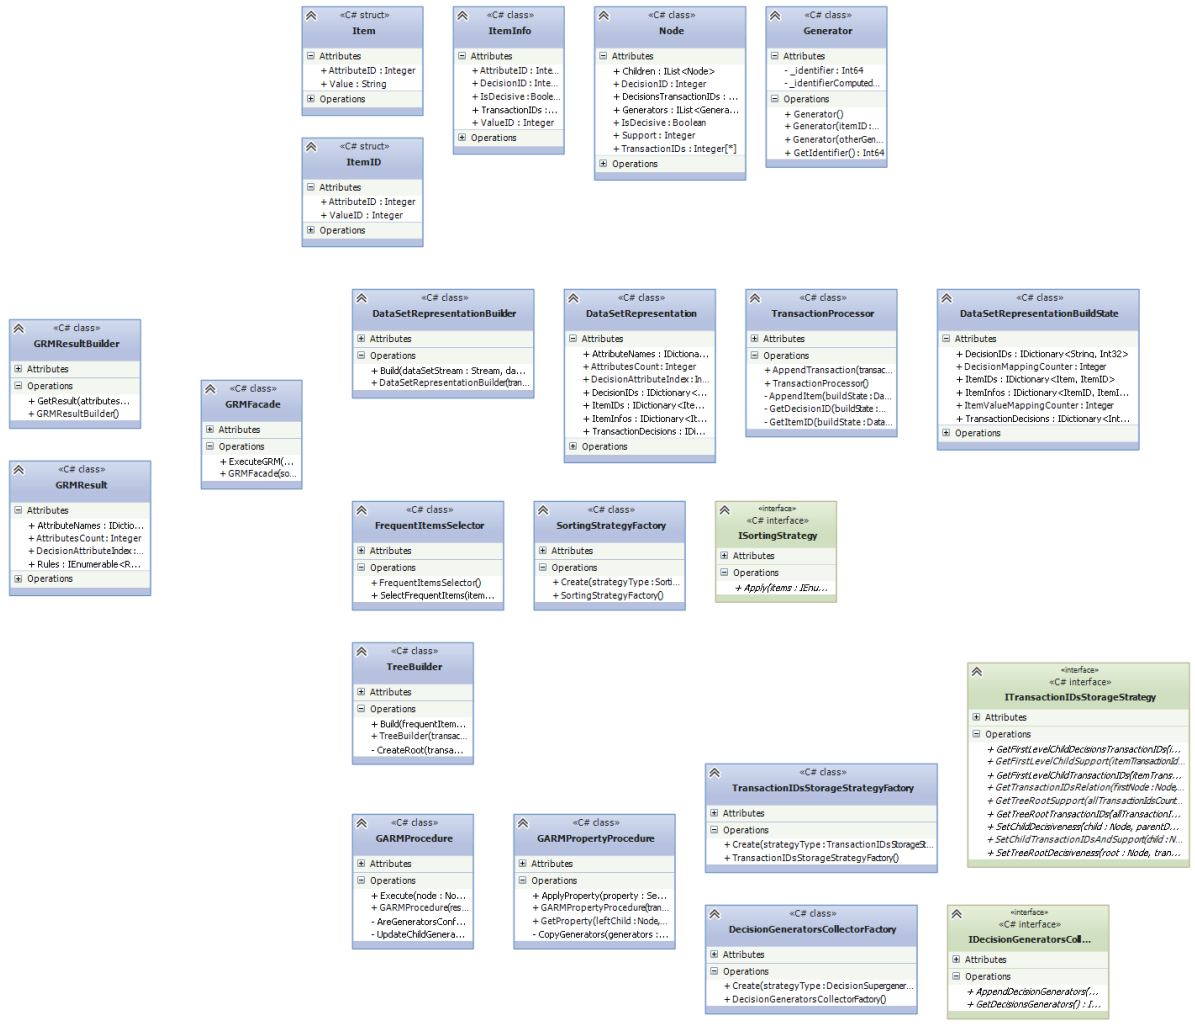

Rysunek 1: Uproszczony diagram klas modułu GRM.Logic.

Punktem wejścia modułu jest klasa `GRMFacade`. Zleca ona wykonanie kolejnych kroków algorytmu. Diagram jej zależności przedstawia Rysunek 2.

[3]Wszystkie zawarte w niniejszym raporcie diagramy można znaleźć w Załączniku C.

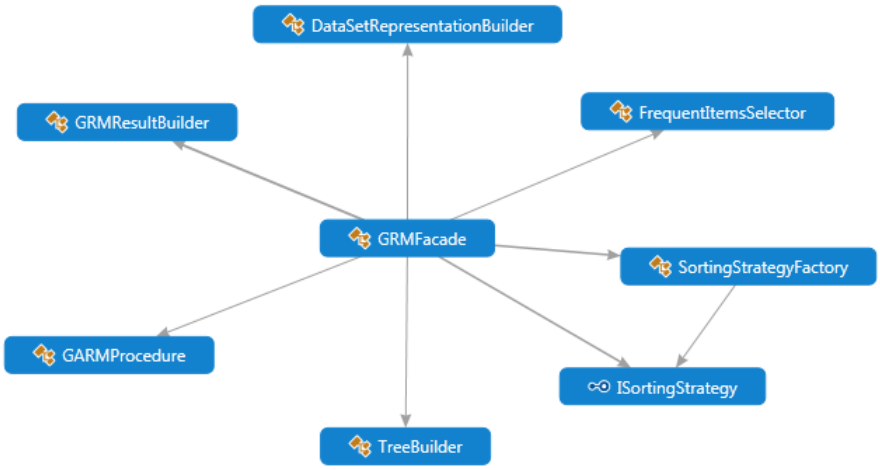

Rysunek 2: Uproszczony diagram zależności fasady modułu GRM.Logic.

Poszczególne kroki algorytmu zaimplementowane są w dwóch komponentach:

- GRM.Logic.DataSetProcessing,
- GRM.Logic.GRMAlgorithm.

5.1.1 Komponent GRM.Logic.DataSetProcessing

Zadaniem komponentu `GRM.Logic.DataSetProcessing` jest odczytanie pliku wejściowego i zbudowanie reprezentacji zbioru danych przeznaczonej do dalszego przetwarzania.

Diagram zależności tego komponentu został przedstawiony na Rysunku 3.

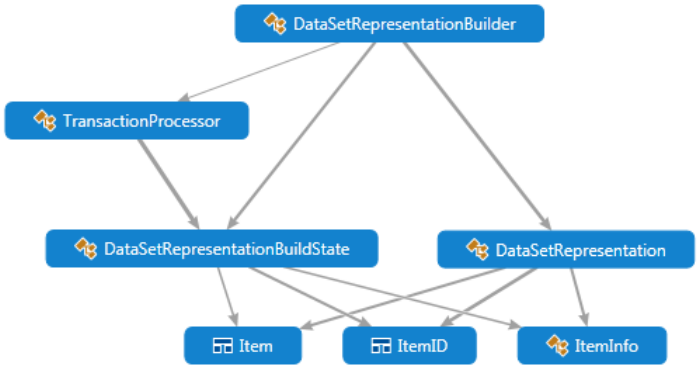

Rysunek 3: Uproszczony diagram zależności komponentu GRM.Logic.DataSetProcessing.

5.1.2 Komponent GRM.Logic.GRMAlgorithm

Komponent GRM.Logic.GRMAlgorithm implementuje zmodyfikowany algorytm GRM. Jego diagram zależności przedstawia Rysunek 4.

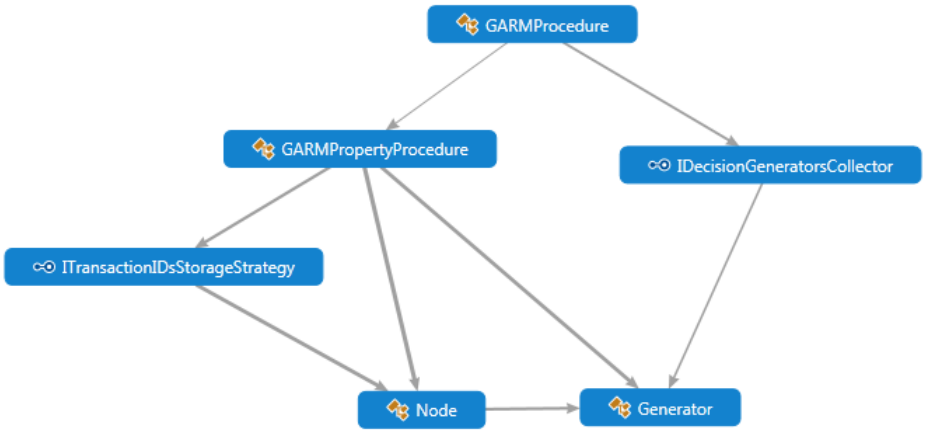

Rysunek 4: Uproszczony diagram zależności komponentu GRM.Logic.GRMAlgorithm.

5.2 Moduł GRM.Presentation

Moduł `GRM.Presentation` odpowiada za komunikację z użytkownikiem aplikacji i zlecenie wykonania algorytmu GRM. Jego diagram klas przedstawia Rysunek 1.

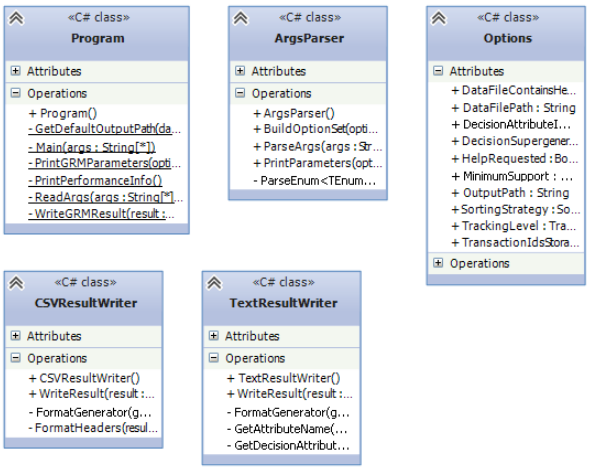

Rysunek 5: Diagram klas modułu GRM.Presentation.

Klasa `Program` zawiera główną metodę programu - `Main`. Jej działanie przebiega następująco:

1. Odczytanie parametrów wiersza poleceń (klasa `ArgsParser`). Błędne parametry skutkują wypisaniem komuniaktu o błędzie i wyjściem z aplikacji.
2. Przekazanie sterowania modułowi `GRM.Logic` (klasie `GRMFacade`).
3. Odebranie wyniku działania algorytmu GRM (`GRMResult`) od klasy `GRMFacade`.
4. Wypisanie zebranych danych o czasach trwania kolejnych kroków algorytmu (patrz sekcja 6.5).
5. Zapisanie wyniku działania algorytmu do pliku wyjściowego w formacie czytelnym dla człowieka (klasa `TextResultWriter`).
6. Zapisanie wyniku działania algorytmu do pliku wyjściowego w formacie przystosowanym do dalszej obróbki (klasa `CSVResultWriter`).

Opisane zachowanie obrazuje diagram zależności pokazany na Rysunku 6.

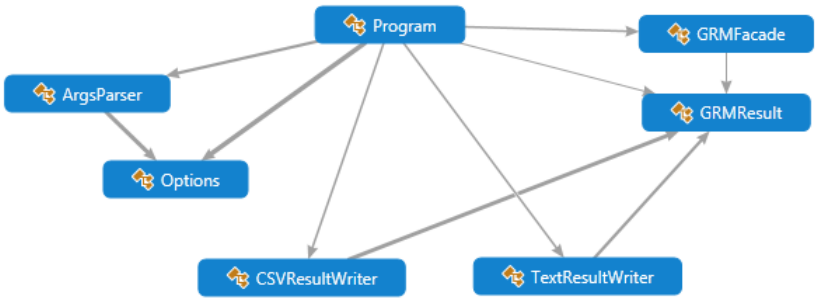

Rysunek 6: Diagram zależności modułu GRM.Presentation. Klasy GRMFacade i GRMResult należą do modułu GRM.Logic.

6 Implementacja

Najważniejsze aspekty implementacyjne opisywanej aplikacji:[4]

6.1 Kroki algorytmu

Działanie modułu `GRM.Logic` przebiega w następujących krokach:
[W nawiasach kwadratowych podano nazwę klasy wykonującej dany krok.]

1. [`DataSetRepresentationBuilder`] Odczytanie pliku wejściowego i budowa reprezentacji zbioru danych:
   (a) określenie liczby atrybutów i odczytanie ich nagłówków (jeśli dostępne);
   (b) dla każdego z wierszy reprezentujących transakcje:
      i. [`TransactionProcessor`] nadanie identyfikatora transakcji,
      ii. [`TransactionProcessor`] dla każdego elementu transakcji:
         A. nadanie identyfikatora elementu (jeśli element o tej wartości jeszcze nie wystąpił),
         B. aktualizacja danych elementu (zbioru transakcji, w których występuje i decyzyjności);
   (c) zwrócenie gotowej reprezentacji danych (`DataSetRepresentation`).
2. [`FrequentItemsSelector`] Wybór elementów częstych.
3. [`ISortingStrategy`] Posortowanie elementów częstych.
4. [`TreeBuilder`] Budowa drzewa zbiorów (drzewa DZ [1]):
   (a) utworzenie korzenia drzewa:
      i. [`ITransactionIDsStorageStrategy`] wyznaczenie zbioru identyfikatorów transakcji korzenia;
   (b) utworzenie pierwszego poziomu węzłów drzewa - dla każdego z elementów częstych:
      i. ustawienie elementu jako generatora węzła,
      ii. [`ITransactionIDsStorageStrategy`] wyznaczenie zbioru identyfikatorów transakcji węzła oraz jego wsparcia i decyzyjności;
   (c) zwrócenie korzenia drzewa zbiorów (`Node`).
5. [`GARMProcedure`] Wywołanie procedury GARM [1].
6. [`GRMResultBuilder`] Budowa i zwrócenie wyniku (`GRMResult`).

[4] Pełny kod źródłowy programu zawiera Załącznik B.

6.2 Strategie sortowania elementów

Zaimplementowano następujące strategie sortowania elementów w drzewie zbiorów:

- `AscendingSupport` (klasa `AscendingSupportSortingStrategy`) - sortowanie rosnące według wsparć elementów,
- `DescendingSupport` (klasa `DescendingSupportSortingStrategy`) - sortowanie malejące według wsparć elementów,
- `Lexicographical` (klasa `LexicographicalSortingStrategy`) - sortowanie leksykograficzne. tzn. według numerów atrybutów elementów (dla dwóch wartości tego samego atrybutu, pierwsza będzie ta, która wcześniej wystąpiła w zbiorze danych wejściowych).

Strategie sortowania dostarcza fabryka `SortingStrategyFactory`, tworząca strategie odpowiadające zadanym wartościom wyliczenia `SortingStrategyType`.

6.3 Strategie przechowywania identyfikatorów transakcji

Zaimplementowano następujące strategie przechowywania identyfikatorów transakcji:

- `TIDSets` [2] (klasa `TIDSetsStorageStrategy`),
- `DiffSets` [1] (klasa `DiffSetsStorageStrategy`).

Strategie przechowywania dostarcza fabryka `TransactionIDsStorageStrategyFactory`, tworząca strategie odpowiadające zadanym wartościom wyliczenia `TransactionIDsStorageStrategyType`.

6.4 Strategie przechowywania generatorów decyzji

Zaimplementowano następujące strategie przechowywania generatorów decyzji, a także wykrywania i usuwania ich nadgeneratorów:

- `InvertedLists` (klasa `InvertedListsDecisionGeneratorsCollector`) - wykorzystuje koncepcję indeksu odwróconego[5], gdzie kluczem indeksu jest element, a wartością - lista generatorów, w których ten element występuje,
- `BruteForce` (klasa `BruteForceDecisionGeneratorsCollector`) - przechowuje jedynie listę generatorów, nadgeneratory wykrywa porównując każdy element danego generatora z każdym elementem jego potencjalnego nadgeneratora.

Strategie dostarcza fabryka `DecisionGeneratorsCollectorFactory`, tworząca strategie odpowiadające zadanym wartościom wyliczenia `DecisionSupergeneratorsHandlingStrategyType`.

6.5 Monitorowanie wydajności programu

Aplikacja udostępnia funkcjonalność mierzenia czasu wykonania poszczególnych kroków algorytmu. Zaimplementowano następujące rodzaje pomiaru:

- `NoTracking` (klasa `EmptyProgressTracker`) - brak pomiaru wydajności,
- `Task` (klasa `TaskProgressTracker`) - pomiar czasu trwania całego algorytmu,
- `Steps` (klasa `StepProgressTracker`) - pomiar czasu trwania głównych kroków algorytmu (odczyt danych wejściowych, wykonanie procedury *GARM* itd.),
- `Substeps` (klasa `SubstepProgressTracker`) - pomiar czasu trwania mniejszych kroków algorytmu (budowanie słownika identyfikatorów decyzji, wykonanie procedury *GARM-Property* itd.). Uwaga: może powodować znaczący spadek ogólnej wydajności programu.

Obiekty monitorujące dostarcza fabryka `ProgressTrackerFactory`, tworząca obiekty odpowiadające zadanym wartościom wyliczenia `TrackingLevel`.

[5] Patrz http://en.wikipedia.org/wiki/Inverted_index.

6.6 Zabiegi optymalizacyjne

- Aby zminimalizować czas odczytu danych wejściowych, plik wejściowy jest odczytywany jednokrotnie, wiersz po wierszu.
- Aby zminimalizować czas trwania porównań, wszystkie wartości atrybutów otrzymują identyfikatory liczbowe.
- Aby zminimalizować czas operacji (np. przecięcia, różnicy) na zbiorach identyfikatorów transakcji, identyfikatory te są przechowywane w ustalonym (rosnącym) porządku.
- Aby możliwie wcześnie "odciąć" gałęzie drzewa, które nie prowadzą do znalezienia generatorów decyzji:
  - jeśli dwa węzły zawierają różne wartości tego samego atrybutu, to nie są "parowane" (tzn. poddawane procedurze *GARM-Property*) - przecięcie zbiorów identyfikatorów transakcji, w których występują jest puste, a zatem ich potencjalne dziecko nie może generować żadnej decyzji;
  - jeśli dany węzeł jest "decyzyjny" (tzn. generuje decyzję), to nie jest dalej rozwijany - generatory jego potencjalnych dzieci byłyby nadgeneratorami jego generatora.
- Jako że generator dowolnej decyzji D_1 nie może być nadgeneratorem żadnego generatora decyzji D_2 ($D_1 \neq D_2$), strategie przechowywania generatorów decyzji (patrz sekcja 6.4) przechowują generatory w słownikach, których kluczami są identyfikatory decyzji, a wartościami - zbiory generatorów tych decyzji. Pozwala to zminimalizować rozmiary porównywanych zbiorów generatorów.
- Granica GBd [1] nie jest tworzona i aktualizowana, jako że nie jest wykorzystywana w poszukiwaniu reguł decyzyjnych.

6.7 Zastosowane praktyki programistyczne

- Test-Driven Development, TDD[6] - najważniejsze funkcjonalności aplikacji powstały zgodnie z zachowaniem kolejności: testy jednostkowe → implementacja → refaktoryzacja.
- Dependency Injection[7] - obiekty klas tworzonych i wykorzystywanych przez klasę `GRMFacade` nie tworzą swoich zależności samodzielnie, a otrzymują je z zewnątrz.
- Wzorce projektowe:
  - Fasada[8] (klasa `GRMFacade`),
  - Budowniczy[9] (para klas: `DataSetRepresentationBuilder` i `TransactionProcessor`),
  - Strategia[10] (strategie opisane wyżej),
  - Fabryka[11] (fabryki strategii opisane wyżej).

6.8 Wykorzystane biblioteki zewnętrzne

1. *NDesk.Options*[12] - ułatwia przetwarzanie parametrów wiersza poleceń,
2. *xUnit.net*[13] - umożliwia tworzenie automatycznych testów jednostkowych,
3. *moq*[14] - wspiera tworzenie automatycznych testów jednostkowych.

[6] Patrz http://pl.wikipedia.org/wiki/Test-driven_development.
[7] Patrz http://pl.wikipedia.org/wiki/Wstrzykiwanie_zależności.
[8] Patrz http://pl.wikipedia.org/wiki/Fasada_(wzorzec_projektowy).
[9] Patrz http://pl.wikipedia.org/wiki/Budowniczy_(wzorzec_projektowy).
[10] Patrz http://pl.wikipedia.org/wiki/Strategia_(wzorzec_projektowy).
[11] Patrz http://pl.wikipedia.org/wiki/Fabryka_abstrakcyjna_(wzorzec_projektowy).
[12] Patrz http://www.ndesk.org/Options.
[13] Patrz http://xunit.codeplex.com/.
[14] Patrz https://github.com/Moq/moq4.

7 Analiza wydajności algorytmu

W celu analizy wydajności programu i wyznaczenia najlepszych strategii wykonywania poszczególnych kroków algorytmu, przeprowadzono badania na czterech zbiorach danych:

- *car*[15],
- *mushroom*[16],
- *nursery*[17],
- *molecular*[18].

7.1 Wybór najlepszej strategii przechowywania generatorów

Celem pierwszego badania było wyznaczenie najlepszej strategii przechowywania generatorów decyzji. Spodziewanym wynikiem była znacząca przewaga strategii `InvertedLists` nad strategią `BruteForce`, jako że ta druga jest strategią zachłanną.

W ramach badania dokonano pomiarów czasu wykonania algorytmu na dwóch zbiorach danych: *nursery* (mała liczba atrybutów, duża liczba transakcji) i *mushroom* (duża liczba atrybutów, średnia liczba transakcji). We wszystkich pomiarach używano strategii sortowania `AscendingSupport` i strategii przechowywania identyfikatorów transakcji `TIDSets`. Wyniki pomiarów przedstawia poniższa tabela:

zbiór danych	*nursery*		*mushroom*	
próg wsparcia; l. reguł	1; 117	10; 60	5; 3239	20; 2635
`BruteForce`	**1.687 s**	**0.917 s**	**21.5 s**	**14.44 s**
`InvertedLists`	**0,733 s**	**0,65 s**	**6,14 s**	**4,98 s**
wzrost wydajności	**57%**	**29%**	**71%**	**66%**

Zgodnie z oczekiwaniami, użycie strategii `InvertedLists` zaskutkowało znaczącym wzrostem wydajności. Badanie pokazało, jak ważna jest optymalizacja kroków związanych z przechowywaniem generatorów decyzji - używając startegii `BruteForce`, krok ten może zająć nawet dwie trzecie ogólnego czasu wykonania programu.

W dalszych badaniach stosowano jedynie strategię `InvertedLists`. Ich wyniki zawiera Załącznik D.

7.2 Wybór najlepszej strategii przechowywania identyfikatorów transakcji

Jak pokazują wyniki pomiarów (patrz Załącznik D), strategia `TIDSets` jest w każdym przypadku lepsza od strategii `DiffSets`. Powodem takiego stanu rzeczy jest najprawdopodobniej duży narzut obliczeniowy dodatkowych operacji związanych z utrzymaniem słownika *decyzja → zbiór identyfikatorów transakcji* (przykładowo, wykrycie zależności pomiędzy węzłami drzewa DZ wykonywane przez procedurę *GARM-Property* jest bardziej skomplikowane dla startegii `DiffSets`, niż `TIDSets`).

7.3 Wybór najlepszej strategii sortowania elementów

Jak pokazują wyniki pomiarów (patrz Załącznik D), dla małego zbioru danych (*car*) strategia sortowania ma niewielki wpływ na wydajność algorytmu. Jednak dla pozostałych zbiorów, szczególnie w przypadkach skutkującym znalezieniem dużej liczby reguł decyzyjnych, wyraźnie najlepsza jest strategia `AscendingSupport`.

Powodem takiego stanu rzeczy jest niższy koszt operacji na zbiorach identyfikatorów transakcji niż w przypadku strategii `DescendingSupport`. Przykładem jest operacja wyznaczenia różnicy posortowanych

[15] Patrz http://archive.ics.uci.edu/ml/datasets/Car+Evaluation.
[16] Patrz http://archive.ics.uci.edu/ml/datasets/Mushroom.
[17] Patrz http://archive.ics.uci.edu/ml/datasets/Nursery
[18] Patrz http://archive.ics.uci.edu/ml/datasets/Molecular+Biology+%28Splice-junction+Gene+Sequences%29.

zbiorów, która jest mniej wydajna, jeśli liczność "lewego" zbioru jest większa niż liczność zbioru "prawego" (częściej występuje wtedy potrzeba uwzględnienia w wyniku - w osobnej pętli - tych elementów zbioru "lewego", które są większe od największego elementu zbioru "prawego").

Strategia `Lexicographical` uplasowała się pomiędzy dwiema pozostałymi - wzajemnie przeciwstawnymi - strategiami. Fakt ten wydaje się zrozumiały - kolejność występowania atrybutów i ich wartości nie powinna mieć decydującego wpływu na żaden z kroków algorytmu.

7.4 Wnioski

Zestaw strategii zapewniający najlepszą wydajność algorytmu, to:

- strategia sortowania: `AscendingSupport`,
- strategia przechowywania identyfikatorów transakcji: `TIDSets`,
- strategia przechowywania generatorów decyzji: `InvertedLists`.

Właśnie te strategie są używane domyślnie przez aplikację.

Niezależnie od wybranego zestawu strategii, wydajność algorytmu spada wraz ze wzrostem liczby atrybutów transakcji (patrz wyniki dla zbiorów *mushroom* i *molecular*). W przypadku zbioru *molecular*, nie udało się wręcz przeprowadzić badania dla progu wsparcia poniżej 50 - nawet kilkugodzinne działanie aplikacji nie kończyło się osiągnięciem wyniku.

Ewentualne dalsze zabiegi optymalizacyjne powinny więc być skupione na wydajności przetwarzania zbiorów danych o dużej liczbie unikalnych elementów (tzn. dużej liczbie wielowartościowych atrybutów). Ogólna wydajność aplikacji jest jednak w pełni zadowalająca.

8 Przykład działania aplikacji

Poniżej przedstawiono przykład działania programu dla niewielkiego zbioru danych[19]:

8.1 Plik wejściowy

Załóżmy, że plik wejściowy został nazwany `input.data`. Zawartość pliku:

```
Attr A,Attr B,Attr C,Attr D,Attr E,Attr F,Attr G,Attr H,Decision
a,b,c,d,e, ,g, ,+
a,b,c,d,e,f, , ,+
a,b,c,d,e, , ,h,+
a,b, ,d,e, , , ,+
a, ,c,d,e, , ,h,-
 ,b,c, ,e, , , ,-
```

8.2 Parametry wiersza poleceń

Aplikacja zostaje uruchomiona z następującymi parametrami:

```
GRM.exe -f input.data -h --sup 3 --track 3
```

8.3 Komunikaty wypisane na konsoli

Na konsoli wypisane zostają następujące komunikaty:

[19] Zbiór danych pochodzi z [1], został on jedynie uzupełniony o decyzje przypisane transakcjom.

```
Executing GRM for file 'input.data'
The file is expected to contain attribute names
Decision attribute: last
Minimum support: 3
Sorting strategy: 'AscendingSupport'
Transaction IDs storage strategy: 'TIDSets'
Decision supergenerators handling strategy: 'InvertedLists'
Performance tracking level: 'Substeps'
Output files will be saved to: 'input'

GRM execution finished
Lasted 00:00:00.1123575
Steps details:
1. Creating data set representation: 00:00:00.0293191
 - Building decision -> decision id dictionary: 00:00:00.0003843 (6 iterations)
 - Building item -> item id dictionary: 00:00:00.0068837 (30 iterations)
 - Including item in data set representation: 00:00:00.0066924 (30 iterations)
2. Selecting frequent items: 00:00:00.0044970
3. Sorting frequent items: 00:00:00.0027784
4. Building GRM tree: 00:00:00.0163098
5. Running GARM procedure: 00:00:00.0418275
 - Checking for node generators conflicts: 00:00:00.0014032 (5 iterations)
 - Determining GARM property: 00:00:00.0020787 (5 iterations)
 - Applying GARM property (sets different): 00:00:00.0052850 (3 iterations)
 - Applying GARM property (sets equal): 00:00:00.0001329 (1 iterations)
 - Including parent node generators in child node generators: 00:00:00.0021305
   (6 iterations)
 - Updating decision generators: 00:00:00.0213280 (1 iterations)
6. Building result: 00:00:00.0163420

Text result saved to input_rules.txt
CSV result saved to input_rules.csv
```

8.4 Plik wyjściowy czytelny dla człowieka

Zawartość pliku wyjściowego w formacie czytelnym dla człowieka (`input_rules.txt`):

```
====================
Decision: '+':
--------------------
Attribute 1 (a), Attribute 2 (b)
Attribute 2 (b), Attribute 4 (d)
```

8.5 Plik wyjściowy do dalszej obróbki

Zawartość pliku wyjściowego w formacie przystosowanym do dalszej obróbki (`input_rules.csv`):

```
Attr A,Attr B,Attr C,Attr D,Attr E,Attr F,Attr G,Attr H,Decision
a;b;;;;;;;+
;b;;d;;;;;+
```

8.6 Analiza poprawności wyniku

Znalezione zostały dwie reguły decyzyjne o minimalnych poprzednikach. Poprawność wyniku potwierdzają następujące fakty:

- Zbiór danych zawiera tylko dwie transakcje o decyzji '-', a próg wsparcia wynosi 3, zatem nie istnieje żadna reguła dla tej decyzji.
- Próg wsparcia osiągają elementy zbioru { a, b, c, d, e }.
  - Minimalne podzbiory tego zbioru występujące jedynie w transakcjach o decyzji '+' to: { a, b }, { b, d }. Zostały one ujęte w wyniku algorytmu.
  - Nieminimalne podzbiory tego zbioru występujące jedynie w transakcjach o decyzji '+' to: { a, b, c }, { b, c, d, }, { a, b, c, d, }. Nie zostały one ujęte w wyniku algorytmu.

9 Uruchamianie aplikacji

Załącznik A zawiera przykładowy skrypt uruchamiający aplikację. Na jego podstawie, tzn. modyfikując jego parametry, należy utworzyć skrypt realizujący żądany tryb działania.

Przydatne informacje:

- wymogi dotyczące danych wejściowych: Sekcja 2.3,
- format pliku wejściowego: Sekcja 3.1,
- spis parametrów aplikacji: Sekcja 3.2,
- opis dostępnych strategii wykonywania poszczególnych operacji: Sekcja 6,
- przykład działania aplikacji: Sekcja 8.

10 Podsumowanie

Podsumowując, wynikiem projektu jest wydajna i elastyczna aplikacja poprawnie wykrywająca reguły decyzyjne o minimalnych poprzednikach, które są częstymi generatorami. Wydajność potwierdzają załączone wyniki testów, elastyczność - przejrzystość diagramów zależności i wymienność kluczowych zachowań, a poprawność - automatyczne testy jednostkowe i integracyjne.

Jedynym znaczącym defektem aplikacji jest jej wydajność dla zbiorów danych o dużej liczbie wielowartościowych atrybutów.

Załączniki

A katalog *app/* - pliki binarne aplikacji wraz z przykładowym zbiorem danych i skryptem uruchamiającym aplikację.

B katalog *source/* - kod źródłowy aplikacji.

C katalog *diagrams/* - diagramy klas i zależności modułów aplikacji.

D katalog *results/* - zestawienie wyników badań wydajności programu.

Literatura

[1] *Odkrywanie reprezentacji generatorowej wzorców częstych z wykorzystaniem struktur listowych*, Kryszkiewicz M., Pielasa P., Instytut Informatyki, Politechnika Warszawska.

[2] *CHARM: An Efficient Algorithm for Closed Itemset Mining* [online], Zaki M., Hsiao C. http://epubs.siam.org/doi/pdf/10.1137/1.9781611972726.27 [dostęp: styczeń 2013].